

1.使用的 AI 模型: ChatGPT / Claude

2.使用的 AI 提示词:

“如何配置 AutoDL 云服务器上的 SGLang 环境并安装指定版本?”

“SGLang 启动时遇到 401 Unauthorized 报错, 该如何解决?”

“写一个 Python 脚本, 模拟泊松到达过程发送并发请求并记录 TTFT 和 Latency。”

“RadixAttention 和 PagedAttention 在机制上的主要联系与差异是什么?”

3.AI 如何帮助我学习:

AI 在环境配置阶段帮助我快速定位了 401 报错的根本原因 (HuggingFace 鉴权问题), 并提供了切换到 ModelScope 镜像源的代码方案 (export SGLANG_USE_MODELSCOPE=true)。在压测阶段, AI 帮我快速生成了包含 TTFT 计算逻辑的 Python 脚本模板。在理论学习阶段, AI 用通俗的语言帮我理清了 RadixAttention、Prefix Reuse 以及 KV Cache 分页管理之间的逻辑关系。

4.在运用 AI 时是否被误导:

在参考 AI 提供的压测脚本时, 我发现 AI 生成的某些复杂封装代码在实际执行时容易引发终端卡顿, 我结合实际情况进行了精简和调整。这提醒我在利用 AI 时, 必须保持批判性思维, 结合本地的实际环境 (如 AutoDL 容器环境) 进行调整, 不能完全依赖。