

1. 简述你是如何完成第一次挑战的：

我首先尝试在本地 Windows 系统上部署 WSL2，但由于系统版本限制失败。随后我转向 AutoDL 云服务器平台，租用了 RTX 4080 SUPER 显卡实例。为了快速搭建环境，我使用了 pip 国内镜像源加速，成功安装了 SGLang 0.5.14 和 Ray 2.56.0。在启动模型时，遇到 HuggingFace 下载报错 401，我通过设置 SGLANG_USE_MODELSCOPE=true 环境变量，利用国内 ModelScope 源成功加载了 Qwen3-0.6B 模型。最后，我编写脚本完成了基于合成负载的压测，成功获取了 TTFT 和 Latency 数据。

2. 你觉得哪部分工作最困难，你是如何克服这个困难的：

最困难的部分在于本地环境搭建和部署时的网络限制。最初在 Windows 配置 WSL2 时遇到系统兼容性问题，后来通过转向云服务器解决。在安装 SGLang 时，模型下载面临网络阻断和授权报错，我通过查阅资料，发现可以灵活运用国内开源镜像源（如 ModelScope 和清华源）来绕过限制。在这个过程中，我学会了如何阅读日志定位问题，并灵活运用环境变量来适配国内网络环境。

3. 你觉得类似的从 0 到 1 的科研工作，需要包含哪些方面的研究，对你今后的科研工作有什么启发：

通过这次实践，我认识到从 0 到 1 的大模型系统研究不仅涉及算法模型本身，还深度依赖底层系统工程。在科研中，不能仅仅停留在模型调用层面，深入理解推理框架（如 SGLang 的 RadixAttention、vLLM 的 PagedAttention）的底层实现，才能在实际业务中优化吞吐量和延迟。这次经历启发我在今后的科研中，要更加注重工程落地能力，学会通过分析真实业务负载来指导系统优化。