

1.SGLang 的 RadixAttention / RadixCache 解决什么问题？

解决大模型在多轮对话或 Few-shot 场景下, 相同前缀 Prompt 被重复计算的问题。它使用基数树在全局内存中管理 KV Cache, 实现了跨请求的前缀复用, 极大降低了首字延迟, 提升了吞吐量。

2. SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分？

page-sized KV cache 对应内存管理部分; prefix reuse 对应 Prefill 阶段, 用来减少重复计算。

3. vLLM 的 PagedAttention 解决什么问题? 它和 SGLang 的 RadixAttention / paged KV 机制有什么联系与差异?

vLLM 的 PagedAttention 主要解决显存碎片化问题, 让并发处理更多请求成为可能。联系: SGLang 的 page-sized KV cache 借鉴了 vLLM 的分页思想。差异: vLLM 重点在分页和内存管理, 而 SGLang 的 RadixAttention 在此基础上, 进一步构建了前缀树, 实现了全局的前缀匹配和共享, 优化了前缀重复计算的问题。