

文献 1: 《SGLang: Efficient Execution of Structured Language Model Programs》 (NeurIPS 2024)

摘要: 该论文提出了 RadixAttention 机制, 这是一种在 KV Cache 中利用基数树实现跨请求前缀自动复用的技术。在多轮对话和重复前缀的 Few-shot 场景中, 该机制能显著减少重复计算, 提升系统吞吐量。

收获: 理解了 SGLang 性能优化的核心在于对 Prefix 的全局共享, 这超越了传统单次请求的 KV Cache 管理, 为高并发服务提供了强大的系统级支撑。

文献 2: 《Efficient Memory Management for Large Language Model Serving with PagedAttention》 (SOSP 2023)

摘要: 该论文提出了 PagedAttention, 借鉴操作系统的分页思想, 将 KV Cache 切分成块进行存储, 有效解决了显存碎片化问题, 极大提升了显存利用率和高并发吞吐量。

收获: 理解了 vLLM 和 SGLang 在底层显存管理上存在共同思想 (均采用分页机制), 但 SGLang 在此基础上更进一步, 实现了前缀级别的树形共享优化。这让我明白推理系统的优化是一个多层次的综合工程。